

UNIVERSIDAD
COMPLUTENSE
MADRID

Sprint 2

Desafios AI

Ética de Datos e IA

Yao Chen

Jiahao Cheng

Jorge Hernández Palop

Alicia Pereda Bordejé

Jiayi Wang

11/10/2026

1 Introducción

Durante este Sprint hemos concretando la arquitectura técnica, creado un *mock-up* de su interfaz de usuario y estudiado distintos desafios éticos y legales.

Primero hemos analizado el Reglamento Europeo de Inteligencia Artifial [1], considerando que nuestro sistema encaja en un sistema de riesgo limitado. También hemos estudiado la Ley Orgánica 1/1982 [2] y a partir de ello hemos propuesto controles para verificar la procedencia de fuentes y la posibilidad de supervisión humana en caso de vulnerar algún derecho. Esto se puede ver en : Apéndice B: responsabilidad legal

Finalmente, hemos estudiado las condiciones legales para utilizar noticias y extraer información a través de *web scraping* y APIs, priorizando el acceso de manera consentida y sin guardar ni reproducir los contenidos originales. Para ver más: Apéndice C: uso de información

2 Arquitectura

Nuestra aplicación permite hacer consultas sobre personas/entidades y temas o sucesos con los que están o han estado implicados. La arquitectura principal será similar a la de un sistema experto. Sin embargo, el motor de inferencia no tendrá solo reglas clásicas si no que serán pipelines basados en modelos de lenguaje. Además habrá un modulo con conexión a Internet que permite obtener nueva información de manera automática o bajo demanda.

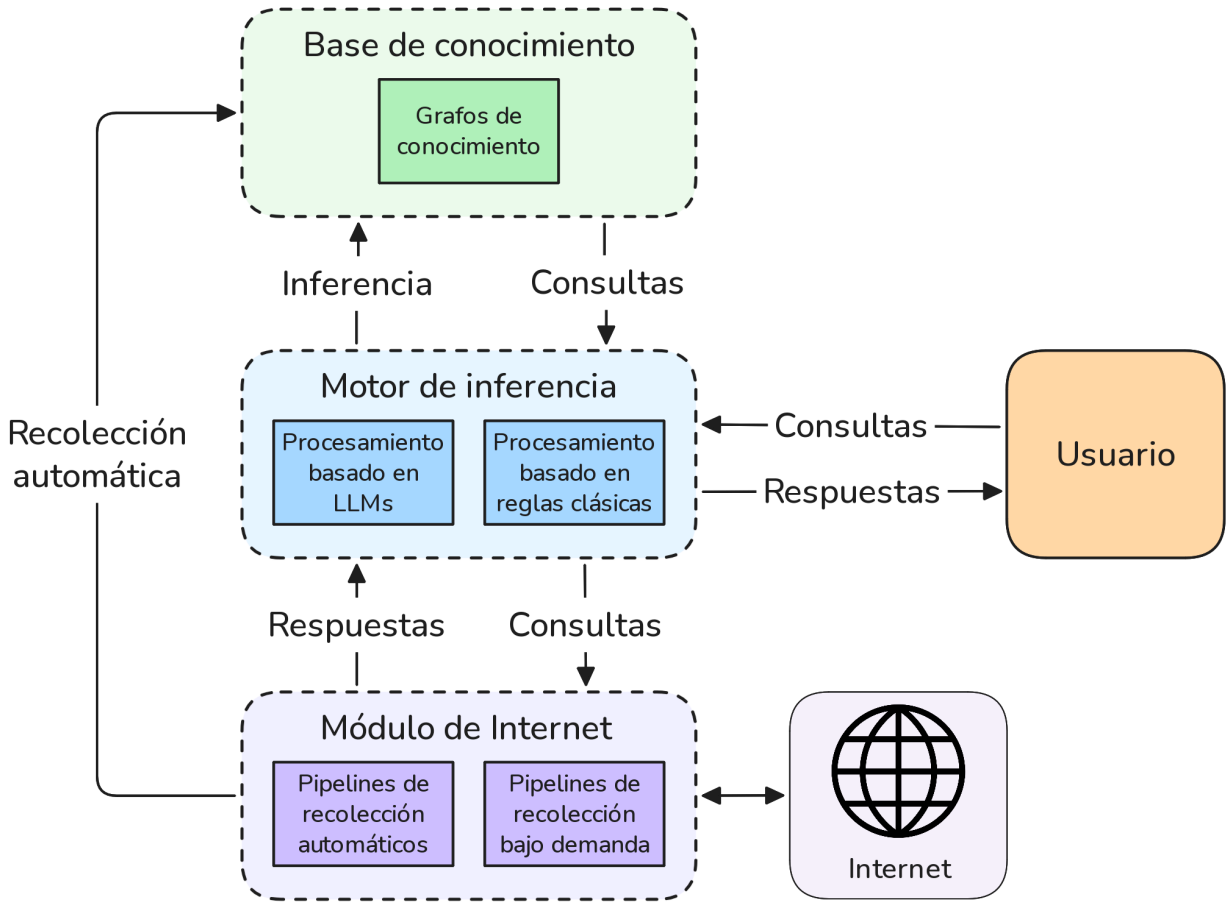


Figura 1: Esquema de la arquitectura de la aplicación

3 Mock-up de la interfaz de usuario

A continuación se presenta un mock-up de la interfaz mínima de nuestro proyecto, ilustrado mediante un caso ficticio sobre una propuesta de transporte público gratuito.

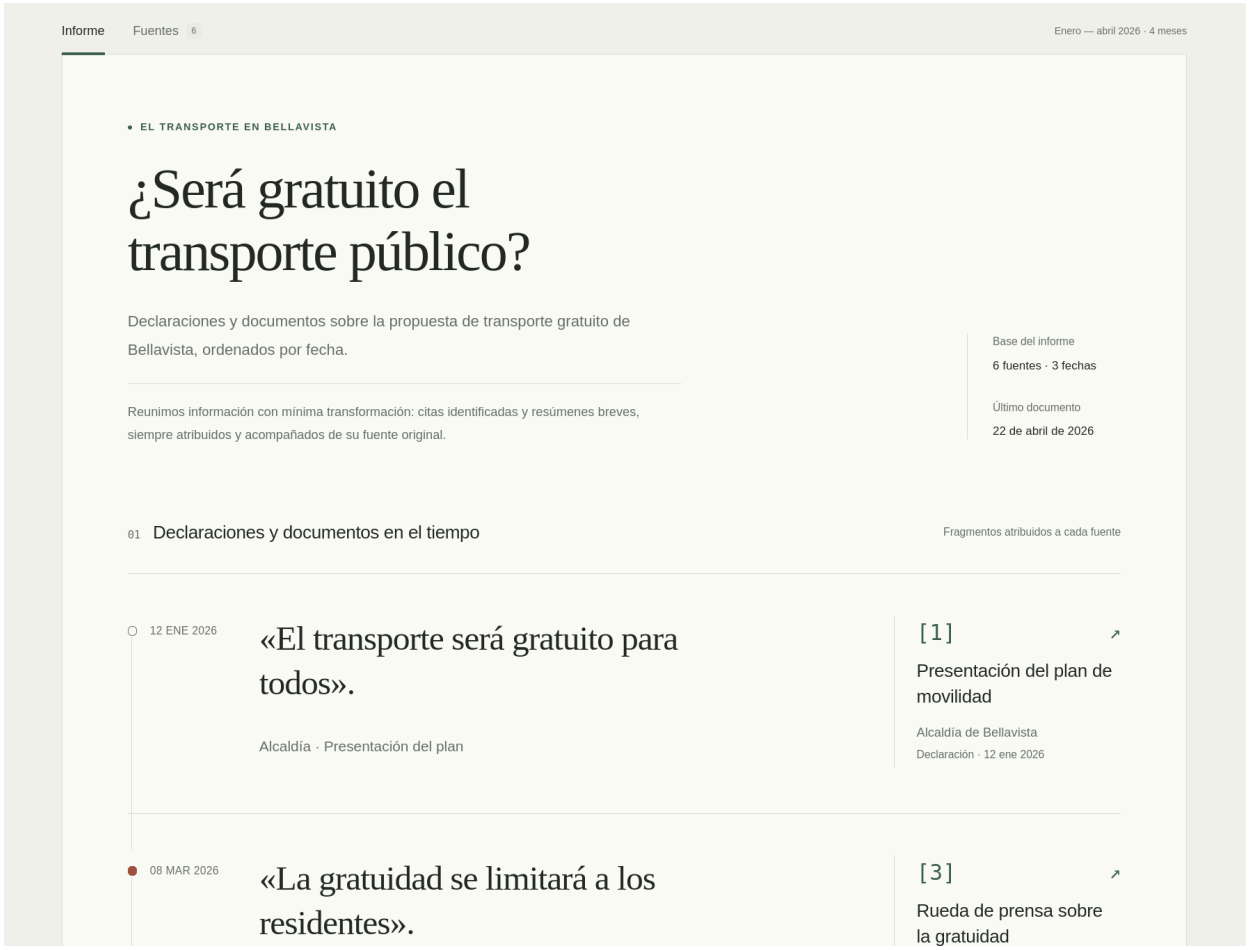


Figura 2: Pestaña Informe



Figura 3: Pestaña Informe: resumen

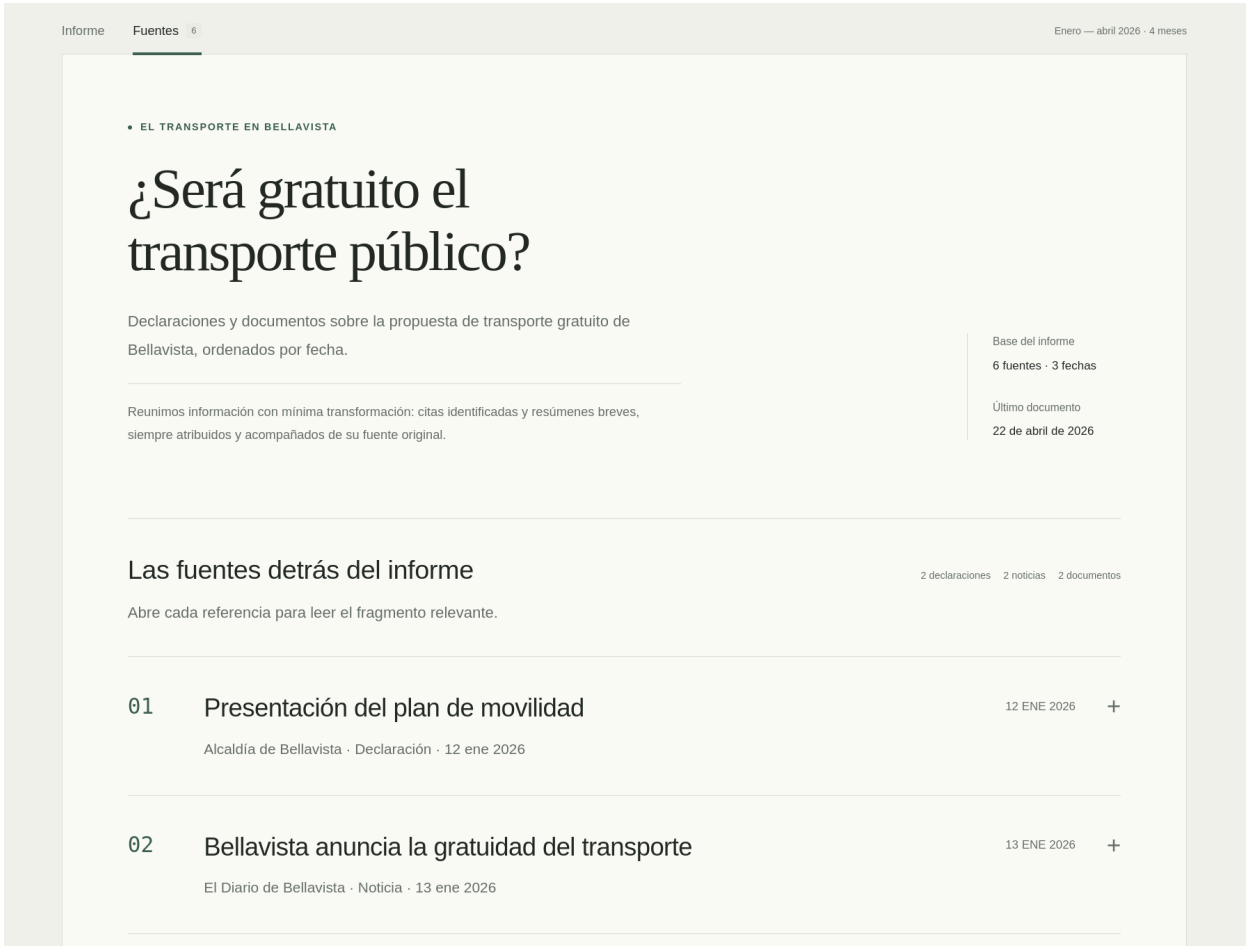


Figura 4: Pestaña Fuentes

La interfaz se organiza en dos pestañas, Informe y Fuentes. La pestaña Informe presenta las declaraciones y los documentos relevantes en orden cronológico, indicando la fecha y el origen correspondiente. El informe termina con un resumen, que reúne los puntos principales mediante citas identificadas. El objetivo es organizar la información con la mínima transformación necesaria, sin presentar el resumen como un veredicto ni sustituir el criterio del usuario.

La pestaña Fuentes reúne las referencias utilizadas en el informe e identifica cada una mediante su título, la persona o entidad responsable y la fecha de publicación. Cada fuente se puede desplegar para leer el fragmento citado y abrir el contenido original. También se puede consultar su información al pasar el cursor sobre una referencia del informe.

4 Desafíos Éticos

A continuación, trataremos sobre diferentes temas de desafíos éticos que debemos considerar en el desarrollo de nuestro proyecto.

4.1 Profundizar Riesgos

Partiendo de los riesgos del Sprint 1, los escalamos a un escenerio de cientos de millones de usuarios. A esa escala, una tasa de error del 1% en los informes generados supone millones de lecturas basadas en información incorrecta. Hay dos grupos de afectados: los usuarios, que reciben una visión errónea, y las personas sobre las que se informa, cuya imagen puede dañarse ante millones de personas. Los riesgos se organizan en tres bloques.

4.1.1 Riesgos derivados de errores del sistema

Difamación y daño reputacional masivo

Aunque TTC no emite conclusiones, sino que muestra información contrastada para que el usuario decida, un 1% de error a escala de cientos de millones de usuarios sigue implicando millones de personas expuestas a una presentación errónea de sus declaraciones. El sistema puede:

- Priorizar fuentes que distorsionan una declaración.
- Atribuir mal una cita o sacarla de contexto.
- Ordenar la información de forma que induzca a una interpretación hostil.

Aunque el usuario «decida por sí mismo», lo hace sobre una base que el sistema ha construido, el resultado podría llegar a ser campañas de acoso o daño reputacional de la figura pública.

Desigualdad en la calidad según idioma y región

La fiabilidad de TTC depende de las fuentes disponibles, y estas no se reparten por igual: hay regiones con poca diversidad de medios o con información concentrada en pocos actores. A escala global, los informes serían sólidos en unos países y frágiles justo donde más falta hace la información contrastada. Así se reproduciría la visión de unos pocos medios, el riesgo que ya señalamos en el Sprint 1 de agravar los sesgos.

4.1.2 Riesgos de manipulación externa

Amplificación de desinformación coordinada

Actores maliciosos podrían inundar las fuentes con desinformación diseñada para ser recogida por TTC y presentada como una fuente más. El efecto sería que en lugar de arrojar luz, el sistema contribuiría a difundir la mentira al integrarla en un contraste aparentemente objetivo.

Uso como arma de guerra informativa

Los gobiernos y otras entidades de poder podrían presionar a la ONG para que retire fuentes o modifique el sistema, o directamente bloquear el servicio en su país. En un conflicto internacional, esto haría que millones de personas recibieran una visión sesgada pero presentada como objetiva. Esa apariencia de neutralidad podría usarse para legitimar decisiones políticas o militares, como sanciones, intervenciones o incluso guerras «demostrando» que el bando contrario es el villano.

4.1.3 Riesgos sistémicos de la escala

Monopolización de la información

Si nuestro sistema llega a usarse a gran escala y tener una influencia grande en la sociedad, nuestro sistema se puede convertir en esa fuente única a la que los usuarios acceden para informarse, de forma que los informes generados por el sistema pasan a definir cómo entiende la realidad una parte importante de la población. Cualquier sesgo podría tener influencia global.

Exceso de confianza

Nuestra idea es generar informes para que el usuario tenga información ordenada en su mano y que pueda contrastar toda la información consultando a las fuentes originales para que pueda reflexionar, bajo su propio criterio, lo que ocurre en la realidad en la que vive. Sin embargo, no se puede descartar que si nuestro sistema llega a tener cierta influencia en la sociedad, el público pueda tener un exceso de confianza en el sistema y no consultar ninguna de las fuentes originales. TTC podría estar influenciando en las opiniones de la gente aunque no es lo que pretenda.

4.1.4 Mitigaciones

Apéndice F: Mitigación de riesgos

4.2 Nuestra postura

Tras debatirlo, hemos llegado a la conclusión de que un **enfoque escéptico** es el más acertado para nuestra organización. Nuestras decisiones de diseño se basan en la documentación de fuentes, transparencia y reproducibilidad del modelo, rechazando conclusiones absolutas. Además, pensamos que se

alinea con nuestro objetivo principal: evitar que una única fuente monopolice la interpretación de los hechos y utilizar la IA como una herramienta que aporte conexto e información pero sin reemplazar el criterio humano.

5 Robustez

El sistema de TheTruthChain no permite al usuario realizar prompts con modelo de lenguaje, ni interactuar con la base de conocimiento de manera imprevista. El usuario solo puede acceder a información sobre personas de interés o información sobre temas que estan disponibles en la base de conocimiento por medio de unas interfaces bastante restrictivas.

Sin embargo, esto no hace que nuestro sistema sea infalible ya que existen bastantes riesgos que amenazan la robustez del sistema desde el punto de vista de la recolección de información. Por ejemplo campañas de desinformación, prompt inyection en las fuentes de información o información remanente que sobrevive una eliminación manual del sistema.

5.1 Personalización

Hemos decidido que TTC **no adaptará el contenido según el perfil del usuario**. TTC ofrecerá una visión lo más objetiva y contrastada posible. La única forma de adaptación permitida será de visualización para crear una mejor experiencia de usuario: idioma de la interfaz, opciones de accesibilidad, tipo de letra y tamaño etc.

Bibliografía

[1] Agencia Española de Supervisión de Inteligencia Artificial, «El Reglamento Europeo de Inteligencia Artificial: aproximacion-general». [En línea]. Disponible en: https://aesia.digital.gob.es/es/actualidad/recursos/ria-aproximacion-general

[2] Jefatura del Estado, «Ley Orgánica 1/1982, de 5 de mayo, de protección civil del derecho al honor». [En línea]. Disponible en: https://www.boe.es/buscar/act.php?id=BOE-A-1982-11196