



UNIVERSIDAD COMPLUTENSE MADRID

Sprint 2

Desafíos AI

Ética de Datos e IA

Yao Chen

Jiahao Cheng

Jorge Hernández Palop

Alicia Pereda Bordejé

Jiayi Wang

11/10/2026

0.1 Profundizar Riesgos

Partiendo de los riesgos del Sprint 1, los escalamos a un escenario de cientos de millones de usuarios. A esa escala, incluso un 1% de error implica a millones de personas afectadas. Los riesgos principales que detectamos:

0.1.1 Difamación y daño reputacional masivo

Aunque TTC no emite conclusiones, sino que muestra información contrastada para que el usuario decida, un 1% de error a escala de cientos de millones de usuarios sigue implicando millones de personas expuestas a una presentación errónea de sus declaraciones. El sistema puede:

- Priorizar fuentes que distorsionen una declaración.
- Atribuir mal una cita o sacarla de contexto.
- Ordenar la información de forma que induzca a una interpretación hostil.

Aunque el usuario «decida por sí mismo», lo hace sobre una base que el sistema ha construido, el resultado podría llegar a ser campañas de acoso o daño reputacional de la figura pública.

0.1.2 Amplificación de desinformación coordinada

Actores maliciosos podrían inundar las fuentes con desinformación diseñada para ser recogida por TTC y presentada como una fuente más. El efecto sería que en lugar de arrojar luz, el sistema contribuiría a difundir la mentira al integrarla en un contraste aparentemente objetivo.

0.1.3 Uso como arma de guerra informativa

Las entidades de poder como el gobierno podrían usar el sistema para sesgar las fuentes y «demostrar» que el bando contrario miente. En ese caso, en conflictos internacionales, millones de personas recibirían una visión sesgada presentada como objetiva, lo que podría justificar guerras o intervenciones.

0.2 Nuestra postura

Tras debatirlo, hemos llegado a la conclusión de que un **enfoque escéptico** es el más acertado para nuestra organización. Nuestras decisiones de diseño se basan en la documentación de fuentes, transparencia y reproducibilidad del modelo, rechazando conclusiones absolutas. Además, pensamos que se alinea con nuestro objetivo principal: evitar que una única fuente monopolice la interpretación de los hechos y utilizar la IA como una herramienta que aporte contexto e información pero sin reemplazar el criterio humano.

Bibliografía