

UNIVERSIDAD
COMPLUTENSE
MADRID

Sprint 3

Implicaciones Sociales

Ética de Datos e IA

Yao Chen

Jiahao Cheng

Jorge Hernández Palop

Alicia Pereda Bordejé

Jiayi Wang

25/10/2026

1 Riesgos y Líneas rojas

En este Sprint hemos dado un paso más en el análisis de los riesgos del proyecto. Para cada uno hemos valorado su gravedad y su probabilidad, y hemos definido cómo prevenirlo y cómo actuar si llega a ocurrir. El resultado se recoge en la tabla de riesgos. Además, hemos fijado cinco líneas rojas, límites que TTC no cruzará en ningún caso.

2 Canal de reclamaciones

Para nuestra aplicación consideramos fundamental crear un canal de reclamaciones accesible para comunicar datos inexactos o posibles vulneraciones de derechos. El usuario puede acceder desde los informes o desde un apartado general, pulsar el botón de reclamaciones y rellenar el formulario indicando su información, el tipo de error, la acción solicitada y explicando el problema. Estas reclamaciones serán revisadas por humanos, clasificando como más urgentes a las que estén relacionadas con vulneraciones de derechos. Finalmente, tomarán una decisión de rectificación, supresión, etc. e informarán tanto al interesado y en ciertos casos se publicará un aviso de corrección. En cuanto a los plazos, nos hemos marcado el objetivo de conseguir respuesta en 10 días laborables para el 80% de las reclamaciones

3 Responsabilidad legal

La responsabilidad legal recae en la propia organización, que deberá asumir las consecuencias de posibles vulneraciones de derechos o daños ocasionados a terceros. Es por ello que consideramos que la implementación y la publicación debe ser de forma responsable y asegurarse de que se cumpla la legislación. Tal cómo establece el art 25 del RGPD [1], la protección de datos se debe integrar desde el diseño y por defecto. Para ello, contaremos con un equipo jurídico encargado de gestionar y supervisar las reclamaciones y solicitudes de revisión; y ayudar a los desarrolladores.

4 Emergencias

Se considera una emergencia cualquier fallo de TTC que pueda causar un daño grave si la información continúa difundiéndose. TTC contará con un responsable técnico y otro de contenidos. Cualquiera de ellos podrá detener el sistema. Los fallos se clasifican en tres niveles según su gravedad:

- **Leve**: errores de formato o enlaces que no cambian el sentido del informe. Se corrigen sin detener el sistema.
- **Grave**: atribuciones falsas que puedan causar un daño grave a una persona o publicación indebida de datos privados. Cuando se confirme al menos un caso, se retirarán temporalmente los informes afectados para revisarlos.
- **Crítico**: manipulación del sistema o fallos cuyo alcance no pueda determinarse. Se detendrá el sistema completo hasta comprobar qué información está afectada.

En los casos graves y críticos se registrará el motivo de la parada y se avisará al equipo encargado de revisar lo ocurrido.

4.1 Revisión humana

La revisión humana estará garantizada en las emergencias y en las reclamaciones de personas afectadas. También se mantendrán las revisiones de los informes más consultados y mediáticos, y la revisión previa cuando existan indicios de obtención ilícita de información y posible vulneración de derechos. El equipo comprobará las fuentes y el contexto de la información para decidir qué debe corregirse o retirarse.

A gran escala, la revisión no abarcará todos los informes. Los casos que puedan causar más daño tendrán prioridad, y los informes que requieran revisión previa quedarán pendientes de publicación. En situaciones como el apagón, mencionado en el debate, también se podrá retrasar la incorporación de información difícil de contrastar mientras se revisan las fuentes.

4.2 Formas de reparación

Tras revisar lo ocurrido, se aplicarán las medidas de reparación que correspondan:

- **Reversión**: se retirará la información errónea y se revisarán los informes que dependan de ella. También se podrá recuperar una versión anterior si sigue siendo válida.
- **Corrección**: se explicará públicamente el error y los cambios realizados, procurando que la corrección llegue a quienes recibieron la información original.
- **Compensación**: la ONG atenderá las solicitudes de indemnización por los daños causados y valorará cada caso, además de cumplir lo que establezcan los tribunales.
- **Prevención**: se analizará la causa del error y se revisarán los controles necesarios para evitar que se repita.

El sistema volverá a funcionar con la autorización de ambos responsables, una vez corregido el fallo y retirada o corregida la información afectada.

5 Usuarios y Colectivos Afectados

TTC lo usarán principalmente el público general, profesionales de la información y auditores. El sistema afecta a las personas sobre las que se informa, medios de información, periodistas y la sociedad. Distinguimos tres relaciones de poder, la ONG frente al usuario, la ONG frente a personas afectadas y entidades de gran poder frente a la ONG.

Las personas con discapacidades, con una baja renta, mayores y con baja alfabetización mediática son los cuatro colectivos más afectados. Los cuatro tienen la berrera de poder contrastar correctamente la información que ofrece TTC con las fuentes originales. Pertener a más de un colectivo sólo refuerza esta barrera.

6 Fuentes de sesgos

Algunas fuentes posibles de sesgo que identificamos en TTC son:

- **datos**: TTC puede presentar sesgos en la selección y cobertura de fuentes, lo que puede causar análisis descontextualizados o subjetivos. También creemos que podrían existir datos históricos discriminatorios que afecten a los resultados y que perpetuen prejuicios presentes en la sociedad. Para prevenirlo prestaremos especial atención en la calidad (declaraciones que provienen de fuentes auténticas, sin manipular, con un contexto conocido) de las fuentes.
- **modelo**: para prevenir sesgos en el modelo, como pueden ser el de posición, por el que se puede dar más importancia al principio y al final de textos, o sesgos relacionados con las reglas del motor de inferencia que puedan favorecer algunas interpretaciones frente a otras, estableceremos criterios objetivos de clasificación y realizaremos evaluaciones para descubrir y corregir sesgos injustificados.

También pueden existir sesgos relacionados con la **presentación visual** del producto o con el propio **equipo de desarrollo**. Para prevenirlo diseñamos una interfaz clara y que no influya en las conclusiones que obtengan los usuarios y documentamos las decisiones tomadas. Cómo ya hemos mencionado anteriormente, hemos creado un canal de reclamaciones que permitirá detectar sesgos nuevos o cualquier otro problema y corregirlos.

7 Compromisos y métricas de equidad

Dada la dificultad objetiva para medir la equidad en la actividad que desarrolla el sistema, se plantea la necesidad de hacer auditorías externas periódicas, con una periodicidad inicial de seis meses, en la cual se evaluarán los siguientes índices:

Equidad en el análisis Diferencia entre los porcentajes de acierto obtenidos al analizar declaraciones de personas agrupadas según características como orientación política o género. Este tratamiento se haría

siguiendo la normativa vigente de protección de datos. Se establece como objetivo interno inicial que la diferencia entre los grupos no sea mayor de un 5%.

Trazabilidad Número de informes que no son posible rehacerlos en base a las fuentes detalladas en él. Se define un objetivo inicial de 0. Este índice se considera fundamental en la medida de la equidad.

Diversidad de fuentes Consideramos que este índice, tiene una métrica dificil de evaluar. Se trata de medir la inclusión de fuentes diversas en los informes elaborados por el sistema. Se propone comenzar con la siguiente métrica: (declaraciones de las 2 fuentes principales / total de declaraciones) x 100. Cuanto más alto sea el valor, menor diversidad de fuentes tendremos. Decidimos no tener un valor inicial de referencia a la espera de obtener medidas reales del sistema.

Registro de correcciones Número de correcciones sobre informes emitidos. Se plantea este índice con el fin de determinar la fiabilidad de los informes emitidos. Se define un objetivo inicial de un 5%

Bibliografía

[1] Parlamento Europeo y Consejo de la Unión Europea, «Reglamento (UE) 2016/679, de 27 de abril de 2016, relativo a la protección de las personas físicas en lo que respecta al tratamiento de datos personales y a la libre circulación de estos datos (Reglamento general de protección de datos)». [En línea]. Disponible en: https://www.boe.es/doue/2016/119/L00001-00088.pdf