

UNIVERSIDAD
COMPLUTENSE
MADRID

Sprint 3

Anexo A: Tabla Riesgos

Ética de Datos e IA

Yao Chen

Jiahao Cheng

Jorge Hernández Palop

Alicia Pereda Bordejé

Jiayi Wang

26/10/2026

1 Tabla de Riesgos

Para valorar cada riesgo usamos una escala de tres niveles de gravedad y probabilidad, suponiendo un escenario de cientos de millones de usuarios:

Nivel	Gravedad	Probabilidad
Baja	Molestia puntual que se corrige sin consecuencia.	Poco probable incluso a gran escala.
Media	Daño real pero limitado y reparable.	Puede ocurrir.
Alta	Daño grave, masivo o difícil de revertir.	Casi seguro a gran escala.

Ya con las escalas definidas:

Nombre	Descripción	Gravedad	Probabilidad	Prevención	Contingencia
Difamación	Error en los informes (citas mal atribuidas, fuera de contexto o mal ordenadas) dañan la reputación de una persona ante millones de usuarios.	Alta	Alta	• Enlazar cada afirmación a su fuente original. • Mostrar citas literales, evitar parafraseo. • Revisión humana en los informes más consultados.	• Canal de rectificación con respuesta pública. • Mostrar la corrección a quienes vieron el original.
Desigualdad Regional	Sesgo por falta de variabilidad en las fuentes de una región o idioma.	Media	Alta	• Indicar cuántas fuentes respaldad el informe y país de origen. • No publicar con fuentes escasas o poco variadas. • Aviso del posible sesgo.	• Revisar los informes afectados. • Buscar fuentes adicionales en la región concreta.
Desinformación Coordinada	Actores malicioso inundan las fuentes con contenido falso para que TTC lo recoja y lo amplifique.	Alta	Alta	• Detectar picos de publicaciones similares. • Priorizar fuentes fiables y documentos primarios.	• Excluir las fuentes implicadas y generar los informes afectados. • Avisar a los usuarios. Publicar caso detectado.
Guerra Informativa	Entidades de poder presionan a la ONG para imponer una visión sesgada con apariencia objetiva.	Alta	Media	• Código abierto verificable. • Diversificar la financiación.	• Hacer pública cualquier tipo de presión o bloqueo. • Publicar informes de transparencia sobre peticiones recibidas.
Monopolización	TTC. se convierte en la fuente única de información y define cómo entiende la realidad gran parte de la población.	Alta	Baja	• Metodología pública y reproducible. • No proporcionar conclusiones y mostrar diferentes puntos de vista.	• Colaborar y apoyar herramientas alternaivas. • Someterse a auditorías externas.
Exceso de Confianza	Los usuarios aceptan el informe sin consultar fuentes originales	Media	Alta	• Interfaz que lleva a las fuentes originales. • Recordar las limitaciones dle informe.	• Medir cuántos usuarios consultan las fuentes. Realizar cambios a partir de ese indicador.

Nombre	Descripción	Gravedad	Probabilidad	Prevención	Contingencia
Prompt Injection	Una fuente incluye instrucciones ocultas que manipulan al modelo de lenguaje al procesarla	Media	Media	• Limpiar el texto de las fuentes. • Separar instrucciones y contenido en el *Prompt*.	• Excluir la fuente y regenerar los informes afectados. • Añadir patrón detectado a los filtros.
Información remanente	Contenido retirado o corregido sigue apareciendo en los informes porque se conserva en la base de conocimiento.	Media	Media	• No guardar copias completas de los contenidos. • Definir un proceso de borrado que recorra todas las capas.	• Retirar de inmediato los informes afectados. • Identificar la capa en la que falló el borrado y corregir. • Informar a los usuarios de lo ocurrido y cómo se ha corregido.

Bibliografía