


UNIVERSIDAD
COMPLUTENSE
MADRID

---

# Sprint 3

# Anexo A: Tabla Riesgos

*Ética de Datos e IA*

---

**Yao Chen**

**Jiahao Cheng**

**Jorge Hernández Palop**

**Alicia Pereda Bordejé**

**Jiayi Wang**

26/10/2026

# 1 Tabla de Riesgos

Para valorar cada riesgo usamos una escala de tres niveles de gravedad y probabilidad, suponiendo un escenario de cientos de millones de usuarios:

| Nivel | Gravedad | Probabilidad |
|---|---|---|
| Baja | Molestia puntual que se corrige sin consecuencia. | Poco probable incluso a gran escala. |
| Media | Daño real pero limitado y reparable. | Puede ocurrir. |
| Alta | Daño grave, masivo o difícil de revertir. | Casi seguro a gran escala. |

Ya con las escalas definidas:

| Nombre | Descripción | Gravedad | Probabilidad | Prevención | Contingencia |
|---|---|---|---|---|---|
| **Difamación** | Error en los informes (citas mal atribuidas, fuera de contexto o mal ordenadas) dañan la reputación de una persona ante millones de usuarios. | Alta | Alta | • Enlazar cada afirmación a su fuente original.<br>• Mostrar citas literales, evitar parafraseo.<br>• Revisión humana en los informes más consultados. | • Canal de rectificación con respuesta pública.<br>• Mostrar la corrección a quienes vieron el original. |
| **Desigualdad Regional** | Sesgo por falta de variabilidad en las fuentes de una región o idioma. | Media | Alta | • Indicar cuántas fuentes respaldad el informe y país de origen.<br>• No publicar con fuentes escasas o poco variadas.<br>• Aviso del posible sesgo. | • Revisar los informes afectados.<br>• Buscar fuentes adicionales en la región concreta. |
| **Desinformación Coordinada** | Actores malicioso inundan las fuentes con contenido falso para que TTC lo recoja y lo amplifique. | Alta | Alta | • Detectar picos de publicaciones similares.<br>• Priorizar fuentes fiables y documentos primarios. | • Excluir las fuentes implicadas y generar los informes afectados.<br>• Avisar a los usuarios. Publicar caso detectado. |
| **Guerra Informativa** | Entidades de poder presionan a la ONG para imponer una visión sesgada con apariencia objetiva. | Alta | Media | • Código abierto verificable.<br>• Diversificar la financiación. | • Hacer pública cualquier tipo de presión o bloqueo.<br>• Publicar informes de transparencia sobre peticiones recibidas. |
| **Monopolización** | TTC. se convierte en la fuente única de información y define cómo entiende la realidad gran parte de la población. | Alta | Baja | • Metodología pública y reproducible.<br>• No proporcionar conclusiones y mostrar diferentes puntos de vista. | • Colaborar y apoyar herramientas alternativas.<br>• Someterse a auditorías externas. |
| **Exceso de Confianza** | Los usuarios aceptan el informe sin consultar fuentes originales | Media | Alta | • Interfaz que lleva a las fuentes originales.<br>• Recordar las limitaciones del informe. | • Medir cuántos usuarios consultan las fuentes. Realizar cambios a partir de ese indicador. |

| Nombre | Descripción | Gravedad | Probabilidad | Prevención | Contingencia |
|---|---|---|---|---|---|
| **Prompt Injection** | Una fuente incluye instrucciones ocultas que manipulan al modelo de lenguaje al procesarla | Media | Media | • Limpiar el texto de las fuentes.<br>• Separar instrucciones y contenido en el *Prompt*. | • Excluir la fuente y regenerar los informes afectados.<br>• Añadir patrón detectado a los filtros. |
| **Información remanente** | Contenido retirado o corregido sigue apareciendo en los informes porque se conserva en la base de conocimiento. | Media | Media | • No guardar copias completas de los contenidos.<br>• Definir un proceso de borrado que recorra todas las capas. | • Retirar de inmediato los informes afectados.<br>• Identificar la capa en la que falló el borrado y corregir.<br>• Informar a los usuarios de lo ocurrido y cómo se ha corregido. |

# Bibliografía