

UNIVERSIDAD
COMPLUTENSE
MADRID

Sprint 4

Anexo F: Debate

Ética de Datos e IA

Yao Chen

Jiahao Cheng

Jorge Hernández Palop

Alicia Pereda Bordejé

Jiayi Wang

08/11/2026

1 Debate

En este anexo, analizamos algunos temas que se trataron en el debate y explicamos las decisiones tomadas tras él.

1.1 Riesgos y líneas rojas

En el debate se señaló una posible contradicción: una de nuestras líneas rojas es no atribuir nunca a nadie una cita falsa, pero en la tabla de riesgos incluimos la posibilidad de que esto ocurra y es alta.

No hay contradicción. Una línea roja es un compromiso de diseño, algo que TTC nunca hará de forma intencionada. Un riesgo es la posibilidad de que, pese a ese compromiso, el sistema falle sin intención, por ejemplo porque un modelo de IA genere una cita inexistente o una transcripción asigne mal una frase.

Declarar el riesgo es lo que permite mitigarlo y cumplir la línea roja.

1.2 Métrica de equidad

Hemos decidido mantener la métrica que utilizamos en el sprint anterior para poder analizar la equidad en el sistema. Este consistía en medir la diferencia entre los porcentajes de acierto obtenidos al analizar declaraciones de personas públicas agrupadas según características como orientación política o género. Por otro lado, nuestra linea roja consistía en que la personalización del perfil, la información que se les muestra a los usuarios, nunca variase por su orientación política u otro rasgo personal. Nos comprometemos, a utilizar esas agrupaciones unicamente durante las auditorías, solo datos de las personas públicas que se analizan con el objetivo de detectar sesgos y nunca para personalización de usuarios.

1.3 Ironía, humor y sátira

Para detectar la ironía, el humor y la sátira usaremos un **LLM como herramienta principal, apoyado por un clasificador**. En 2024, los LLM de entonces, como GPT-4 o Claude 3, todavía rendían peor que modelos preentrenados más pequeños ajustados para detectar sarcasmo [1]. Esperamos que los modelos disponibles en 2030 reduzcan esa diferencia, pero no podemos darlo por hecho, sobre todo en las variantes del español y en las lenguas cooficiales. Los dos modelos reciben la frase junto a su contexto. Con esa información, cada afirmación del grafo recibe una **etiqueta**: literal, irónica, humorística o dudosa.

La etiqueta no sirve para juzgar a nadie, sino para decidir **cómo se usa la afirmación**. Si los dos modelos coinciden, se usa su etiqueta; si no coinciden, la afirmación se marca como dudosa. Solo las afirmaciones literales se usan para relacionarlas con otras o para señalar contradicciones. Las irónicas, humorísticas o dudosas **se tratan como no literales**: en el informe aparecen con el aviso «posible ironía» y su contexto completo, para que sea el usuario quien las valore. Así, ante la duda, **preferimos perder una contradicción antes que atribuir a alguien una postura que no tiene**. Mediremos la precisión de ambos modelos por idioma y variante del español, publicaremos los resultados y revisaremos con ellos qué peso tiene cada uno.

Bibliografía

[1] Y. Zhang, C. Zou, Z. Lian, P. Tiwari, y J. Qin, «SarcasmBench: Towards Evaluating Large Language Models on Sarcasm Understanding», *arXiv preprint arXiv:2408.11319*, 2024, [En línea]. Disponible en: https://arxiv.org/abs/2408.11319