

UNIVERSIDAD
COMPLUTENSE
MADRID

Sprint 4

Anexo G: Plan de entrenamiento sin violación de copyright

Ética de Datos e IA

Yao Chen

Jiahao Cheng

Jorge Hernández Palop

Alicia Pereda Bordejé

Jiayi Wang

08/11/2026

1 Introducción

TTC no entrena un modelo desde cero, al menos por ahora. Usa modelos preentrenados y recupera información del grafo, que guarda afirmaciones, metadatos, enlaces y fragmentos breves, no artículos completos. La mayor parte del riesgo de copyright no está en entrenar, el riesgo está en qué y cómo mostramos los datos al usuario. Por eso separamos lo que recogemos, lo que usamos para entrenar o ajustar un modelo y lo que aparece en los informes.

En resumen si no tenemos clara la licencia, si no está cubierta por la excepción de minería de textos y datos o si las condiciones no nos dejan usarla, no entra.

2 De dónde salen los datos

Los datos abiertos y de dominio público son la base más cómoda: licencias como CC0, CC BY, CC BY-SA u ODbL nos dejan usarlos si cumplimos sus condiciones [1]. Las fuentes oficiales también nos sirven, pero miramos sus condiciones de reutilización y no reproducimos el documento entero. En prensa nos apoyamos en la excepción de minería de textos y datos, siempre que no haya reserva de derechos. En redes sociales usamos la API oficial y sus términos [2]. Para libros y artículos, acceso abierto, licencias o suscripciones que permitan el uso. Obviamente no usaremos nada de bibliotecas piratas. Con audio y vídeo, solo lo que permita la licencia o la plataforma. Y si alguien nos manda contenido, pedimos permiso o que venga con licencia clara.

La excepción española está en el artículo 67 del TRLPI, en la redacción del Real Decreto-ley 24/2021 [3]. Permite reproducir y extraer obras accesibles de forma legítima para minería de textos y datos, pero no publicar la obra completa ni usar el contenido para otras cosas. El apartado 3 excluye el uso si el titular ha reservado expresamente ese derecho por medios de lectura mecánica. Esa reserva es la que detectamos y respetamos.

El artículo 4 de la Directiva (UE) 2019/790 es la norma europea que permite la minería de textos y datos [4]. Se aplica a cualquiera, pero el titular puede reservarse ese uso. El artículo 3 también permite minería, pero solo para organismos de investigación y patrimonio cultural; no es nuestro caso, así que no lo usamos.

Tampoco ignoramos el derecho sobre las bases de datos: si alguien ha invertido en crear una base de datos, no podemos extraer una parte importante de su contenido para fines que no sean minería [5]. Para minería, la extracción sí está cubierta.

Hay dos límites más. El primero es el derecho de los editores de prensa del artículo 15: podemos usar extractos muy breves y enlaces, pero un extracto largo puede necesitar licencia. El segundo son los términos de servicio: aunque la ley de copyright permita copiar para minería, una plataforma puede prohibir el *scraping* en sus condiciones. Por eso usamos APIs oficiales y acuerdos.

3 Cómo lo comprobamos y qué hacemos

Antes de meter una fuente nueva hacemos una ficha con la URL, la fecha, la licencia, las condiciones de uso, el `robots.txt`, la reserva de TDM y los usos permitidos. Esa ficha se queda en el registro de procedencia. Si no está completa, la fuente no se usa; si es nueva o dudosa, pedimos revisión jurídica. Los datos personales y las reclamaciones se gestionan en el canal del Sprint 3.

La reserva de derechos la comprobamos con `robots.txt` y con los metadatos de TDM [6]. No saltamos muros de pago, no falseamos el *user agent* y no evitamos los límites de acceso. Si una fuente se reserva el uso, no la usamos para minería. Si un titular retira una fuente o reserva sus derechos, se aplica el procedimiento de reclamaciones y borrado que ya está en el documento principal.

También filtramos lo que sale: los informes no reproducen artículos completos ni capítulos de libros, solo citas breves con atribución y enlace a la fuente.

4 Entrenamiento y modelos

Si hacemos *fine-tuning* o entrenamiento para alguna etapa del procesamiento, el dataset pasa por un protocolo más estricto. Volvemos a revisar licencia y procedencia, quitamos datos personales y contenido con reserva de TDM. Entrenamos y evaluamos con datos separados, revisamos sesgos y calidad.

5 Datos masivos y gobernanza

Para escalar no hacemos *scraping* indiscriminado. Priorizamos datos abiertos y oficiales, APIs con condiciones claras y acuerdos con medios o agregadores. Common Crawl y otros corpus grandes no son una barra libre: contienen material protegido y no siempre tienen procedencia verificable. Si los usamos, será con filtros de licencia y procedencia. Tampoco usamos datos sintéticos sacados de obras protegidas sin permiso.

El plan lo revisa el equipo y, antes de producción, una persona con formación jurídica. Cada fuente tiene su ficha y cada modelo su documentación; las reclamaciones se gestionan en el canal del Sprint 3. Una vez al año revisamos fuentes, licencias y plazos de conservación.

Bibliografía

[1] Creative Commons, «About CC Licenses». Accedido: 8 de noviembre de 2026. [En línea]. Disponible en: https://creativecommons.org/share-your-work/cclicenses/

[2] X Corp., «X Developer Agreement and Policy». Accedido: 8 de noviembre de 2026. [En línea]. Disponible en: https://developer.x.com/en/developer-terms/agreement-and-policy

[3] Jefatura del Estado, «Real Decreto-ley 24/2021, de 2 de noviembre, de transposición de directivas de la Unión Europea en las materias de bonos garantizados, distribución transfronteriza de organismos de inversión colectiva, datos abiertos y reutilización de la información del sector público, ejercicio de los derechos de autor y derechos afines aplicables a determinadas transmisiones en línea y a las retransmisiones de programas de radio y televisión, establecimiento de un mecanismo de ajuste en frontera por emisión de carbono, y por el que se modifican la Ley 11/2015, de 18 de junio, y el texto refundido de la Ley de Propiedad Intelectual». Accedido: 8 de noviembre de 2026. [En línea]. Disponible en: https://www.boe.es/buscar/act.php?id=BOE-A-2021-17910

[4] Parlamento Europeo y Consejo de la Unión Europea, «Directiva (UE) 2019/790 sobre los derechos de autor y derechos afines en el mercado único digital». Accedido: 8 de noviembre de 2026. [En línea]. Disponible en: https://eur-lex.europa.eu/eli/dir/2019/790/oj

[5] Parlamento Europeo y Consejo de la Unión Europea, «Directiva 96/9/CE sobre la protección jurídica de las bases de datos». Accedido: 8 de noviembre de 2026. [En línea]. Disponible en: https://eur-lex.europa.eu/eli/dir/96/9/oj

[6] IETF, «RFC 9309: Robots Exclusion Protocol». Accedido: 8 de noviembre de 2026. [En línea]. Disponible en: https://www.rfc-editor.org/rfc/rfc9309.html